哈尔滨工业大学（深圳）

Harbin Institute of Technology, Shenzhen

机器学习概论 实验（三）任务书

题 目：基于朴素贝叶斯（或其它方法）的文本分类算法

院　　（系）计算机科学与技术

实验背景

文本分类是一项重要的自然语言处理任务，旨在将文本按照其内容或主题分为不同的类别。在本实验中，需使用朴素贝叶斯算法或其他相关方法，进行文本分类实验。

本次实验为**新闻标题文本分类**，根据给出的新闻标题文本和标签训练一个分类模型，然后对测试集的新闻标题文本进行分类。

实验目的

1. 理解文本分类的基本概念和任务；
2. 学习如何使用朴素贝叶斯算法或其他方法进行文本分类；
3. 实现一个文本分类模型，能够对给定的新闻标题文本进行分类；
4. 评估分类模型的性能，并进行结果分析和讨论。

数据集介绍

本实验使用的是处理后的 THUCNews 数据集。THUCNews 是根据新浪新闻 RSS 订阅频道 2005~2011 年间的历史数据筛选过滤生成，包含 74 万篇新闻文档，均为 UTF-8 纯文本格式。在原始新浪新闻分类体系的基础上，重新整合划分出 14 个候选分类类别：**财经、彩票、房产、股票、家居、教育、科技、社会、时尚、时政、体育、星座、游戏、娱乐**。

数据集内含训练集、验证集和测试集三个文件，文件均为 txt 格式。训练集包含 678998 条数据，验证集包含 75636 条数据，测试集包含 77837 条数据。文本格式为：**新闻标题文本 类别**。数据内容示例如下：

巴萨 1 年前地狱重现这次却是天堂 再赴魔鬼客场必翻盘 体育

美国称支持向朝鲜提供紧急人道主义援助 时政

增资交银康联 交行夺参股险商首单 股票

夏日大学游园会 诺基亚 E66 红黑独家对比 科技

实验步骤

1. 数据准备与数据预处理
   a. 加载和预处理数据集，确保数据格式正确并进行必要的预处理步骤，如分词等；
   b. 将文本数据转换为机器学习算法可以处理的特征表示形式；
2. 构建网络模型，进行模型训练
   a. 需要选择使用朴素贝叶斯算法或其他相关方法进行文本分类；
   b. 使用训练集数据训练分类模型，并更新模型的参数以获得较好的性能；
   c. 设置合适的训练轮数和批量大小，控制模型的训练过程。
3. 模型评估
   a. 使用验证集对训练好的模型进行评估，选择合适的评估指标评估模型；
   b. 分析评估结果，探究模型的性能和潜在改进方向。
4. 撰写实验报告
   a. 展示实验结果，包括模型的准确率和其他评估指标，撰写实验报告。
   b. 探讨实验中遇到的问题、挑战和解决方案。

实验报告要求

实验报告要求包含以下内容:

1. 实验目的和背景介绍；
2. 数据集的描述和处理方式；
3. 实验步骤、训练过程和关键代码的展示；
4. 实验结果的展示和分析、对模型性能的讨论；
5. 对实验过程中遇到的问题和解决方案、实验心得体会等。

其他注意事项

1. 本次实验可进行组队，每组人数为 1~2 人；
2. 为体现工作量，推荐自己实现代码，而非直接使用现成的框架；
3. 实验报告和代码具体提交方式后续通知；

4. 如果组队，需在实验报告内写清组队信息，以及自己在组内负责的工作；
5. 实验报告和代码提交截止日期：2026年5月31日
6. 实验报告或代码有抄袭行为，按 0 分处理。